

Classificação intervalar com aplicação em imagens coloridas

Rodrigo Augusto Dias Faria

Orientador: Prof. Dr. Roberto Hirata Jr

Instituto de Matemática e Estatística
Universidade de São Paulo

São Paulo, 2016



Agenda

- 1 Introdução
- 2 Fundamentação Teórica
 - Modelos de cores
 - Teoria fuzzy
 - Classificadores
- 3 Experimentos Preliminares
 - Conjunto de dados UCI
 - Conjunto de dados SFA
 - Primeiro experimento
 - Segundo experimento
 - Terceiro experimento
- 4 Plano de Trabalho

Motivação

- Em muitos problemas, não há dificuldade em determinar se um dado elemento é ou não parte de um grupo
- $7 \in \mathbb{N}$ e $-7 \notin \mathbb{N}$
- Diversos fenômenos na natureza não podem ser classificados com conjuntos clássicos
- Relação de pertinência não é bem definida (Pedrycz e Gomide, 1998)
- Incerteza e imprecisão nos conjuntos de dados
- Explorar a capacidade de conjuntos *fuzzy* de expressar transições graduais de pertinência e não pertinência

Motivação



Trabalhos relacionados

Classificação com conjuntos *fuzzy*

- Algoritmo de árvore de decisão *fuzzy* (Umano *et al.*, 1994), adaptado do ID3 clássico proposto por Quinlan (1986)
- Bhatt *et al.* (2009) segmentaram regiões de pele no espaço RGB; cinco *clusters* com *fuzzy c-means* (Bezdek *et al.*, 1984)
- *FuzzyDT* proposta por Cintra *et al.* (2013), baseado no C4.5 (Quinlan, 1993)
- Formulação geral de *kernel* sobre conjuntos *fuzzy* (Guevara *et al.*, 2014)

Trabalhos relacionados

Detectores de pele

- Regra de decisão Bayesiana com um modelo de histograma 3-dimensional; histogramas de tamanho 32 mostraram o melhor desempenho com uma taxa de erro de 88% (Jones e Rehg, 2002)
- Classificação com regras no modelo de cores YCbCr; taxa de verdadeiro positivo de 90,66% (Kovac *et al.*, 2003)
- Yogarajah *et al.* (2011) desenvolveram uma técnica onde os limiares definidos nas regras são adaptados dinamicamente

Trabalhos relacionados

Comparação do modelo de cores

- Desempenho ótimo dos classificadores de pele é independente do modelo de cores (Albiol *et al.*, 2001)
- Abordagens Gaussiana e histograma em 805 imagens coloridas em 9 espaços de cores distintos; SCT, HSI e CIELab com abordagem de histograma (Jayaram *et al.*, 2004)
- 10 espaços de cor com base no *k-means* em 15 imagens do AR; YCgCr, YDbDr e **HSV** (Chaves-González *et al.*, 2010)
- Kaur e Kranthi (2012) similar ao proposto por Kovac *et al.* (2003) com operações morfológicas e de filtragem no YCbCr e **CIELab**, ignorando o componente de luminância em ambos
- Técnica similar implementada em Shaik *et al.* (2015) e Kumar e Malhotra (2015) nos espaços de cores HSV e **YCbCr**

Objetivos

- Estudo de conjuntos e números *fuzzy*
- Modelagem de conjuntos *fuzzy* para classificação
- Estudo de classificação *fuzzy*
- Escolher uma aplicação real para aplicar a modelagem *fuzzy*
- Compreender a influência do espaço de cores para a modelagem dos dados

Introdução

- Os seres humanos têm a capacidade de discernir milhares de tonalidades e intensidades
- A percepção humana das cores se dá pela ativação de células nervosas que enviam mensagens ao cérebro sobre brilho (*brightness*), matiz (*hue*) e saturação (*saturation*)
- As cores podem ser especificadas por modelos matemáticos em tuplas de números em um sistema de coordenadas

Modelo de Munsell





Diagrama de cromaticidade CIE 1931

- Primeiro modelo matemático de especificação numérica da cor
- Componente de luminância Y; X e Z de cromaticidade (tristímulus)
- Derivações do CIE XYZ:
CIE 1976 $L^*u^*v^*$ e 1976
CIE $L^*a^*b^*$



Modelos da família YUV

- Y = luminância, U = Azul - Y, V = Vermelho - Y
- Utilizado em sistemas de transmissão analógica de televisão nos padrões PAL e SECAM
- YCbCr é um modelo desta família e é largamente utilizado em vídeos digitais

$$\begin{bmatrix} Y \\ Cb \\ Cr \end{bmatrix} = \begin{bmatrix} 0.299 & 0.587 & 0.114 \\ -0.169 & -0.331 & 0.5 \\ 0.5 & -0.419 & -0.081 \end{bmatrix} \begin{bmatrix} R \\ G \\ B \end{bmatrix}$$

Modelos da família HSI

- (I)ntensidade é decomposta da informação de cromaticidade

$$H = \begin{cases} 60 \frac{(G - B)}{M - m}, & \text{se } M = R \\ 60 \frac{(B - R)}{M - m} + 120, & \text{se } M = G \\ 60 \frac{(R - G)}{M - m} + 240, & \text{se } M = B \end{cases}$$

$$S = \begin{cases} \frac{(M - m)}{M}, & \text{se } M \neq 0 \\ 0, & \text{caso contrário} \end{cases}$$

$$V = M$$

Introdução

- Visão tradicional e alternativa da ciência sobre a incerteza (Klir e Yuan, 1995)
- Com base na ideia moderna de que a incerteza é algo útil na ciência, Zadeh propôs a teoria de conjuntos *fuzzy*
- Capacidade de conjuntos *fuzzy* expressarem transições graduais de pertinência e não pertinência
- Representação significativa e poderosa da medida de incerteza
- Forma de expressar conceitos vagos em linguagem natural

Conjuntos *fuzzy*

Da teoria de conjuntos clássicos tem-se a função característica:

$$\mu_A(x) = \begin{cases} 1 & \text{se } x \in A \\ 0 & \text{se } x \notin A \end{cases}$$

Que é um mapeamento dos elementos de U no conjunto binário $\{0, 1\}$:

$$\mu_A = U \rightarrow \{0, 1\}$$

$\forall x \in U$, se $\mu_A(x) = 1$, então $x \in A$, se $\mu_A(x) = 0$, então $x \notin A$.

Em conjuntos *fuzzy*, generalização aplicada no intervalo $[0, 1]$:

$$\mu_A = U \rightarrow [0, 1]$$

Conjuntos *fuzzy*

Definição de conjuntos *fuzzy*

Um conjunto *fuzzy* A é um subconjunto do conjunto universo U formado por pares ordenados de um elemento qualquer x e seu grau de pertinência dado por $\mu_A(x)$, da forma:

$$A = \{(x, \mu_A(x)) \mid x \in U\}$$

As noções de inclusão, união, intersecção, complemento, relação, convexidade, etc., oriundas da teoria de conjuntos clássica, são estendidas a esses conjuntos (Zadeh, 1965).

Conjuntos *fuzzy*

- U pode ser composto por elementos discretos ou ser um espaço contínuo
- A mesma implicação vale para o subconjunto A
- Quando U é um conjunto discreto e finito, tal que $U = \{x_1, x_2, x_3, \dots, x_n\}$, pode-se simplesmente enumerar os seus elementos, juntamente com seus graus de pertinência:

$$A = \frac{\mu_A(x_1)}{x_1} + \frac{\mu_A(x_2)}{x_2} + \dots + \frac{\mu_A(x_n)}{x_n} = \sum_{i=1}^n \frac{\mu_A(x_i)}{x_i}$$

Conjuntos *fuzzy*

Definição de altura

A altura de A , denotado por $altura(A)$, corresponde ao limite superior do codomínio da sua função de pertinência, da forma:

$$altura(A) = \{\mu_A(x) \mid x \in U\}$$

Definição de suporte

O suporte de um conjunto *fuzzy* A em U , denotado por $suporte(A)$, é o conjunto dado por:

$$suporte(A) = \{x \in U \mid \mu_A(x) > 0\}$$

Conjuntos *fuzzy*

Definição de α -corte ou α -nível

Um α -corte ou α -nível, é o subconjunto clássico de elementos cujo grau de pertinência é maior ou igual a um valor α , formalmente:


$$\alpha - \text{corte}(A) = \{x \in U \mid \mu_A(x) \geq \alpha\}$$

Definição de núcleo ou *kernel*

O núcleo ou *kernel* de um conjunto *fuzzy* A em U , é o conjunto de elementos pertencentes inteiramente à A , da forma:

$$\text{núcleo}(A) = \{x \in U \mid \mu_A(x) = 1\}$$

Representação gráfica das principais propriedades dos conjuntos *fuzzy*



Números *fuzzy*

Um número *fuzzy* é um tipo especial de conjunto *fuzzy* definido no conjunto \mathbb{R} dos números reais, da forma (Klir e Yuan, 1995):

$$A : \mathbb{R} \rightarrow [0, 1]$$


Para que A seja, de fato, um número *fuzzy*, o conjunto universo no qual μ_A está definida deve ser \mathbb{R} e as seguintes propriedades devem ser satisfeitas (Barros e Bassanezi, 2006):

- (i) todos os α -corte de A são não vazios, com $0 \leq \alpha \leq 1$
- (ii) todos os α -corte são intervalos fechados de \mathbb{R}
- (iii) $\text{suporte}(A) = \{x \in U \mid \mu_A(x) > 0\}$

Funções de pertinência

Um número *fuzzy* A é dito triangular se sua função de pertinência, denotada por $\mu_A(x)$, é da forma:


$$\mu_A(x) = \begin{cases} \frac{x-a}{m-a}, & \text{se } a < x \leq m \\ \frac{b-x}{b-m}, & \text{se } m < x < b \\ 0, & \text{c.c.} \end{cases}$$



Funções de pertinência

Um número *fuzzy* A é dito trapezoidal se sua função de pertinência, denotada por $\mu_A(x)$, é da forma:


$$\mu_A(x) = \begin{cases} \frac{x-a}{b-a}, & \text{se } a < x < b \\ 1, & \text{se } b \leq x \leq c \\ \frac{d-x}{d-c}, & \text{se } c < x < d \\ 0, & \text{c.c.} \end{cases}$$



Funções de pertinência

Um número *fuzzy* A é dito gaussiano se sua função de pertinência, denotada por $\mu_A(x)$, é da forma:

$$\mu_A(x) = \begin{cases} \exp\left(-\frac{(x-m)^2}{\sigma}\right), \\ \text{se } m - \sigma \leq x \leq m + \sigma \\ 0, \text{ c.c.} \end{cases}$$



Introdução

Seja o conjunto de dados de treinamento com N amostras da forma:

$$D = (x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)$$

onde $i = 1, 2, \dots, N$, $y_i \in Y$ e $Y = \{+1, -1\}$, e cada x_i é um vetor d -dimensional da forma:


$$x = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_d \end{bmatrix}$$

onde $x \in X$ e X é o espaço de entrada, ou seja, todos os x vetores possíveis.

Máquinas de Vetores Suporte (SVM)

- SVMs têm a habilidade de gerar um hiperplano ou conjunto de hiperplanos num espaço de alta ou infinita dimensionalidade (Duda *et al.*, 2012)
- Assumindo que D é linearmente separável (Lorena e Carvalho, 2003):

$$w \cdot x + b = 0$$



Máquinas de Vetores Suporte (SVM)

Outros dois hiperplanos paralelos ao hiperplano ótimo podem ser obtidos:

$$\begin{cases} w \cdot x + b = +1 \\ w \cdot x + b = -1 \end{cases}$$

Restrições são definidas para evitar que não existam pontos entre $w \cdot x + b = 0$ e $w \cdot x + b = \pm 1$ (Lorena e Carvalho, 2003):

$$\begin{cases} w \cdot x_i + b \geq +1, & \text{se } y_i = +1 \\ w \cdot x_i + b \leq -1, & \text{se } y_i = -1 \end{cases}$$

ou, equivalentemente:

$$y_i(w \cdot x_i + b) \geq 1$$

Máquinas de Vetores Suporte (SVM)

- A minimização de $\|w\|$ maximiza a margem e, sendo assim, tem-se um problema de otimização
- w e b ótimos que resolvem este problema definem o classificador e podem ser obtidos por multiplicadores de Lagrange (Campbell, 2000):

$$\text{Maximizar: } \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j y_i y_j x_i \cdot x_j$$

$$\text{Sujeito a: } \begin{cases} \alpha_i \geq 0 \\ \sum_{i=1}^N \alpha_i y_i = 0 \end{cases}$$

Máquinas de Vetores Suporte (SVM)

SVMs lineares podem ser estendidas:

$$D' = (\Phi(x_1), y_1), (\Phi(x_2), y_2), \dots, (\Phi(x_N), y_N)$$

A forma do hiperplano ótimo agora é definida por:

$$w \cdot \Phi(x) + b = 0$$

O problema de otimização pode ser resolvido como (Lorena e Carvalho, 2003):

$$\text{Maximizar: } \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j y_i y_j \Phi(x_i) \cdot \Phi(x_j)$$

Máquinas de Vetores Suporte (SVM)

Kernels são funções que têm a finalidade de projetar os vetores de entrada num espaço de características com número de dimensões exponencial ou infinito (Shawe-Taylor e Cristianini, 2004):

$$k(x_i, x_j) = \Phi(x_i) \cdot \Phi(x_j)$$

Alguns dos *kernels* mais utilizados são (Lorena e Carvalho, 2003):

- *Kernel* linear

$$k(x_i, x_j) = (x_i \cdot x_j)$$

- *Kernel* polinomial


$$k(x_i, x_j) = (\gamma x_i \cdot x_j + r)^g$$

- *Kernel* gaussiano ou RBF

$$k(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$$

k -Vizinhos Mais Próximos (k -NN)

- k -NN é um algoritmo baseado em instâncias
- Rotula uma nova amostra x com a classe de maior frequência dentre as k mais próximas
- Decisão por maioria de votos (Duda *et al.*, 2012)



k -Vizinhos Mais Próximos (k -NN)

A distância entre duas amostras x_i e x_j quaisquer pode ser obtida em termos da distância Euclidiana:

$$d(x_i, x_j) = \sqrt{\sum_{r=1}^d (a_r(x_i) - a_r(x_j))^2}$$

Para classificar uma nova amostra x_q (Mitchell, 1997):

$$g(x_q) = \operatorname{argmax}_{y \in Y} \sum_{i=1}^k \delta(y, f(x_i))$$

onde

$$\delta(y, f(x_i)) = \begin{cases} 1, & \text{se } y = f(x_i) \\ 0, & \text{caso contrário} \end{cases}$$

k -Vizinhos Mais Próximos (k -NN)

- Uma variação da função é a atribuição de pesos a cada um dos k vizinhos, conforme sua distância
- Implica que pontos mais próximos de x_q têm maior influência na sua rotulação

$$g(x_q) = \operatorname{argmax}_{y \in Y} \sum_{i=1}^k w_i \delta(y, f(x_i))$$

onde

$$w_i = \frac{1}{d(x_q, x_i)^2}$$

No caso em que $d(x_q, x_i) = 0$, $g(x_q)$ pode assumir o mesmo valor de $f(x_i)$ (Mitchell, 1997).

Árvores de decisão

- Processo iterativo onde um atributo (nó) é escolhido como raiz até algum nó folha, onde a classe é atribuída à amostra
- ID3 avalia cada atributo através de um teste estatístico para determinar o quão bem ele, por si só, classifica as amostras de treinamento (Quinlan, 1986)
- O melhor atributo é selecionado como o nó raiz da árvore
- Um ramo descendente do nó raiz é criado para cada valor possível deste atributo (Mitchell, 1997)
- Algoritmo de busca guloso (Mitchell, 1997)
- C4.5 estende o ID3 para possibilitar o uso de atributos contínuos, dados ausentes e poda da árvore Quinlan (1993)

Árvores de decisão

Para medir a impureza de uma partição, o ID3 usa o conceito de entropia (Quinlan, 1986):

$$H(D) = -y_{\oplus} \log_2 y_{\oplus} - y_{\ominus} \log_2 y_{\ominus}$$

O teste estatístico, conhecido como ganho de informação, mede a efetividade de um atributo na classificação dos dados (Quinlan, 1986):

$$IG(D, a_r) = H(D) - \sum_{v \in V(a_r)} \frac{|D_v|}{|D|} H(D_v)$$

onde $V(a_r)$ é o conjunto de todos os possíveis valores do atributo a_r , D_v é o subconjunto de D no qual o atributo a_r tem o valor v .



Repositório da Universidade da Califórnia em Irvine

- Contém 245.057 amostras obtidas de imagens do PAL e FERET (Minear e Park, 2004; Phillips *et al.*, 1996)
- 194.198 são de pixels não pele e 50.859 de pixels de pele
- Compostas por 3 atributos $x = [x_1, x_2, x_3]$, $x \in \mathbb{R}^3$, que representam os canais do modelo de cores RGB
- Uma quarta coluna determina a classe a qual a amostra x pertence, denotada por y , sendo $y \in Y$ e $Y = \{+1, -1\}$

Amostras do conjunto de dados

| B | G | R | Classe |
|-----|-----|-----|--------|
| 74 | 85 | 123 | 1 |
| 207 | 215 | 255 | 1 |
| 74 | 82 | 122 | 1 |
| 202 | 211 | 255 | 1 |
| 54 | 72 | 125 | 1 |
| ... | ... | ... | ... |
| 166 | 164 | 116 | -1 |
| 148 | 150 | 91 | -1 |
| 29 | 26 | 5 | -1 |
| 167 | 166 | 115 | -1 |
| 180 | 177 | 133 | -1 |

Visão 3-dimensional dos canais RGB



Banco de imagens de faces do FERET e AR


- 876 imagens de faces obtidas do FERET, criado por Phillips *et al.* (1996) e 242 do AR, proposto por Martínez e Benavente (1998)
- As imagens do AR têm fundo branco e pequenas variações de cor da pele e, portanto, o ambiente é mais controlado
- Três amostras de pele e cinco não pele foram geradas aleatoriamente considerando a máscara *ground truth* de cada imagem

Exemplos de imagens do banco de faces





Estrutura das janelas

- Cada amostra é uma janela de tamanho $n \times n$, sendo n ímpar, que varia de 1×1 até 35×35
- O conjunto de dados foi gerado com janela 9×9 , totalizando 724.464 amostras, sendo 271.674 de pele e 452.790 não pele



Visão 3-dimensional dos canais RGB



Primeiro experimento

- Realizado com k -NN e SVM no espaço de cores RGB
- Estratégia de validação cruzada *10-fold* em ambos
- Os parâmetros ótimos foram:
 - **k -NN:** $n_neighbors=3$, $weights=uniform$ no UCI e $n_neighbors=15$, $weights=uniform$ no SFA
 - **SVM:** $kernel=rbf$, $C=100$ e $gamma=1e-3$ em ambos UCI e SFA

Tabela de busca

| <i>kernel</i> | <i>C</i> | | | | <i>gamma</i> | | | <i>degree</i> | |
|---------------|----------|----|-----|------|--------------|------|------|---------------|---|
| rbf | 1 | 10 | 100 | 1000 | 1e-3 | 1e-4 | 1e-5 | | |
| poly | 1 | 10 | 100 | 1000 | | 1e-4 | 1e-5 | 3 | 4 |
| linear | 1 | 10 | 100 | 1000 | | | | | |

Tabela: Tabela de busca dos parâmetros do estimador ótimo na SVM.

| <i>n_neighbors</i> | | | | | | | | | | <i>weights</i> | | <i>algorithm</i> |
|--------------------|---|---|----|----|----|-----|-----|-----|-----|----------------|---------|------------------|
| 3 | 5 | 9 | 15 | 25 | 50 | 100 | 200 | 400 | 800 | distance | uniform | auto |

Tabela: Tabela de busca dos parâmetros do estimador ótimo no k-NN.

Resultados

O treinamento foi executado com 10 tarefas em paralelo em ambos os classificadores e 30% dos dados, aleatoriamente, foram separados para teste.

| Dados | Classificador | Modelo de cores | <i>Precision</i> | <i>Recall</i> | <i>F1-score</i> |
|-------|---------------|-----------------|------------------|---------------|-----------------|
| UCI | <i>k</i> -NN | RGB | 0,9995 | 0,9995 | 0,9995 |
| | SVM | RGB | 0,9995 | 0,9995 | 0,9995 |
| SFA | <i>k</i> -NN | RGB | 0,9672 | 0,9669 | 0,9670 |
| | SVM | RGB | 0,9643 | 0,9628 | 0,9638 |

Segundo experimento

- Realizado com k -NN e SVM usando o conjunto de dados SFA nos espaços de cores RGB, HSV, Lab e YCbCr
- O componente de luminância foi ignorado para que um teste somente com os componentes de crominância fosse realizado
- Estratégia escolhida de validação cruzada *10-fold*
- Os parâmetros ótimos obtidos no primeiro experimento foram fixados aqui
- Treinamento com 10 tarefas em paralelo, 30% dos dados, aleatoriamente, foram separados para teste

Resultados

| Modelo de cores | Classificador | <i>Precision</i> | <i>Recall</i> | <i>F1-score</i> |
|-----------------|---------------|------------------|---------------|-----------------|
| RGB | <i>k</i> -NN | 0,9672 | 0,9669 | 0,9670 |
| | SVM | 0,9643 | 0,9628 | 0,9638 |
| HSV | <i>k</i> -NN | 0,9676 | 0,9673 | 0,9674 |
| | SVM | 0,9718 | 0,9677 | 0,9679 |
| HS | <i>k</i> -NN | 0,9215 | 0,9194 | 0,9199 |
| | SVM | 0,9305 | 0,9302 | 0,9302 |
| Lab | <i>k</i> -NN | 0,9671 | 0,9660 | 0,9670 |
| | SVM | 0,9675 | 0,9665 | 0,9672 |
| ab | <i>k</i> -NN | 0,9444 | 0,9439 | 0,9440 |
| | SVM | 0,9451 | 0,9447 | 0,9446 |
| YCbCr | <i>k</i> -NN | 0,9679 | 0,9677 | 0,9677 |
| | SVM | 0,9635 | 0,9633 | 0,9632 |
| CbCr | <i>k</i> -NN | 0,9487 | 0,9482 | 0,9483 |
| | SVM | 0,9496 | 0,9492 | 0,9493 |

Terceiro experimento

- Realizado com árvore de decisão *fuzzy* proposta por Cintra *et al.* (2013) usando o conjunto de dados SFA nos espaços de cores RGB, HSV, Lab e YCbCr
- Os parâmetros do *FuzzyDT* podem ser customizados para determinar a poda da árvore e o método de estimativa do número de conjuntos *fuzzy* por atributo
- Desenvolvido um algoritmo de tabela de busca para encontrar os parâmetros ótimos

Tabela de busca

| Dados | Nível de confiança | | | | Método | | | | # conj. <i>fuzzy</i> |
|-------|--------------------|----|----|----|----------|----|----|-------|----------------------|
| | | | | | infogain | wm | rf | fixed | |
| RGB | 10 | 15 | 20 | 25 | infogain | wm | rf | fixed | 2-9 |
| HSV | 10 | 15 | 20 | 25 | infogain | wm | rf | fixed | 2-9 |
| Lab | 10 | 15 | 20 | 25 | infogain | wm | rf | fixed | 2-9 |
| YCbCr | 10 | 15 | 20 | 25 | infogain | wm | rf | fixed | 2-9 |

Resultados

| Modelo de cores | Taxa de erro | Método | # conjuntos <i>fuzzy</i> |
|-----------------|--------------|--------|--------------------------|
| RGB | 3,00 | fixed | 4 |
| HSV | 3,23 | fixed | 3 |
| Lab | 2,84 | fixed | 6 |
| YCbCr | 2,72 | fixed | 8 |

Disciplinas cursadas

| Disciplina | Término |
|--|----------------|
| Aprendizagem Computacional: Modelos, Algoritmos e Aplic. | 1º Sem/2015 |
| Introdução à Computação Gráfica | 1º Sem/2015 |
| Visão e Processamento de Imagens - Parte I | 1º Sem/2015 |
| Análise de Algoritmos | 2º Sem/2015 |
| Métodos de Aprendizagem em Visão Computacional | 2º Sem/2015 |
| Linguagens, Autômatos e Computabilidade | 1º Sem/2016 |
| Programação Orientada a Objetos | 1º Sem/2016 |

Atividades previstas

- 1 Revisar leituras adicionais
- 2 Incorporar novos conjuntos de dados
- 3 Investigar características passíveis de uso em classificadores de dados intervalares
- 4 Desenvolver ferramentas para dar suporte aos experimentos subsequentes
- 5 Elaborar novos experimentos com base nas ferramentas desenvolvidas e conjuntos de dados estabelecidos
- 6 Analisar os resultados e reportá-los no projeto de pesquisa
- 7 Publicar resultados em artigos científicos
- 8 Escrever a dissertação

Cronograma

| Atividade | Meses 2016/2017 | | | | | | | | | | |
|-----------|-----------------|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|
| | dez | jan | fev | mar | abr | mai | jun | jul | ago | set | out |
| 1 | x | x | x | | | | | | | | |
| 2 | x | x | | | | | | | | | |
| 3 | | x | x | | | | | | | | |
| 4 | | | x | x | x | x | | | | | |
| 5 | | | | | x | x | x | | | | |
| 6 | | | | | | x | x | x | | | |
| 7 | | | | | | | x | x | | | |
| 8 | | | | | | | | x | x | x | x |